

EBG · 25 JUIN 2026

Choisir ses technologies d'agents

Une grille de décision, pas un catalogue d'outils.

Jonathan Gross · Ingénieur Senior Data & AI — **Maxime Lamborelle** · Consultant Senior Data & AI

Klee Group : Conseil & Déploiement



La puissance de l'AI, l'expertise de Klee Group : dopez vos services numériques métier, sans compromis sur la qualité et la sécurité.

CONSEIL & SOLUTIONS

Conseil en Transformation



- Stratégie & cadrage de la transformation
- Conduite du changement & UX/UI
- Innovation & design de service

Développement applicatif



- Solutions sur mesure, évolutives & sécurisées
- Modèles spécifiques, hybride ou low code
- Plateforme modulaire & interopérable

FP&A, Conso & ESG



- Pilotage de la performance financière
- Clôture, consolidation & reporting
- Plateformes (OneStream) & ESG

Solutions Atlassian, EasyVista



- Partenaire Platinum Atlassian
- Collaboration, agilité & efficacité
- Environnements de travail hybrides

AI & Data



- Gouvernance & compliance et valorisation des données
- IA générative, prédictive & agentique
- AI & Data platforms

Agence digitale



- Expériences utilisateurs fluides & sans couture
- Parcours omnicanaux hyper personnalisés
- Engagement & fidélisation

CENTRE D'EXCELLENCE

Cybersécurité



- Sensibilisation, audit technique & Security by Design

DevSecOps



- Automatisation, supervision & sécurité intégrées

Cloud



- Adoption, migration & exploitation, FinOps & GreenOps



Une approche globale, un ancrage métier fort · de l'idée à la solution opérationnelle, durable & industrielle

Klee Group : Focus sur offre AI & DATA :

4 piliers, 2 dimensions transverses.



Conseil – Stratégie AI & Data

Cadrage stratégique, business case, roadmap de transformation - approche pragmatique & agnostique

Gouvernance Data & AI

- Data & AI Compliance (RGPD, KYC, IA Act, Agec, PPD, ...)
- Data & AI Governance, Observability
- Data Catalog & Lineage
- CDO Dashboard & Data Governance opérationnelle
- Politiques & éthique, Sécurité et conformité

Architecture AI & Data

- Stacks data modernes, Data Platform
- Data Management & Data Quality
- Plateformes Agentique, AI RAG et ML
- Master Data Architecture
- Infrastructure Cloud
- Standards et bonnes pratiques

Build & Run

- Développer, tester, déployer et opérer des plateformes data modernes & Plateformes AI industrialisées
- Master Data Repository (Customer, Supplier Product, Asset, Location, Employés, ...)
- Product Information Management project

IA ML, Générative et Agentique

- Roadmap Data & AI
- Transformation AI & Adoption
- DataScience and ML accelerator (Scoring and valeur Client, Fraude, Risque, ...)
- Gouvernance & structuration des corpus documentaire AI RAG



Conduite du changement

Acculturation, montée en compétences, évolution culturelle · alignement & adoption durable

« Choisir ses technologies d'agents »

Frameworks open-source

LangGraph · CrewAI · AutoGen — frameworks de développement d'agents (comportement, prompts, tools...)

C'est pareil

Code vs Low-code/No-code

Pas important

Frameworks des clouds

Bedrock Agents · Vertex Agent Builder · Foundry Agent Service

C'est pareil

Frameworks SaaS métier

Agentforce (Salesforce) — agents collés aux données de l'éditeur

Parfait si répond au besoin, sur vos données

Type de modèle & localisation

API propriétaire → API sur AWS/Azure/GCP → Modèle sur vos VM (sur AWS/Azure/GCP) →
Modèle open-source en local

Demandez à votre RSSI

NOTRE ANGLE

Ces choix technologiques ne sont pas si compliqués.

Implémenter son premier agent

1

Définir et cadrer le use case

Audience · intégrations · gouvernance · tests · ...

2

Choisir la techno & l'archi

NON BLOQUANT

3

Construire

4

Évaluer

Jeux de tests · métriques · non-régression · red-teaming

5

Exploiter

Observabilité · maîtrise des coûts · itération en production

NOTRE ANGLE

Les choix techno, c'est **1 étape sur 5** — ne restez pas bloqués dessus. Ce qui va faire réussir (ou échouer) un agent, c'est tout le reste.

Bien choisir sa techno d'agent — en 3 réflexes

① Situez le use case sur l'échelle d'autonomie.

Le niveau d'autonomie visé commande tout le reste.

② Bâissez un socle agentique réutilisable.

Un même socle — runtime, mémoire, identité, gateway, garde-fous, observabilité — accueille **tous** vos use cases, à **tous** les échelons.

③ Repérez où se loge vraiment le lock-in.

Le modèle et le framework se changent ; le runtime, lui, vous engage. Choisissez-le en conscience.

Le **socle reste le même** ; c'est le **niveau d'autonomie** du use case qui **dimensionne ce qu'on pose dessus**.

L'échelle d'autonomie — illustrée par Léa, au Service Client




Le même besoin de Léa gravit l'échelle — plus d'autonomie = plus de **valeur** ET plus de **risque** à gouverner.

L'ARCHITECTURE QUI SE DÉFORME

Une seule archi — les boîtes s'allument selon l'échelon

☐ allumée ☒ gouvernance renforcée ☐ éteinte

le socle partagé sert tous les use cases



N5 **Système multi-agents** Une seule boîte en plus (**orchestration A2A**). Le reste : de la gouvernance qui brille plus fort.

L'autonomie ne se paie pas en briques techniques — **elle se paie en gouvernance.**

3 couches — un lock-in différent par couche

Modèle

LE CERVEAU

Claude · GPT · Gemini / Llama · Mistral · Qwen — interchangeable via une **abstraction API** (LLM gateway · [LiteLLM](#))

SWAPPABLE

Framework

OÙ L'ON CODE LA LOGIQUE

[LangGraph](#) /... — il y en a beaucoup : neutres (CrewAI · Pydantic AI) ou alignés cloud (AWS Strands · Google ADK · MS Agent Framework). **Le choix importe peu**, il dépend surtout du cloud.

LE PLUS MINCE

Runtime

HÉBERGE ·
SÉCURISE ·
OBSERVE

[AWS Bedrock AgentCore](#) — mémoire, identité, gateway/MCP, observabilité.
Le vrai lock-in est ici : ces couches *stateful* managées ne se déménagent pas d'un clic.

ALIGNER SI CLOUD

Ne stressiez pas sur le choix du cloud. Bedrock AgentCore ≈ Microsoft Foundry Agent Service ≈ Google Agent Runtime (Gemini Enterprise, ex-Vertex) : **même socle**, agnostiques au modèle et au framework. On illustre avec AWS — la méthode ne change pas.

Code vs Low-code/No-code



Le no-code a donné **un peu** de pouvoir au business.
Les LLM donnent le pouvoir du **code** à **tout le monde**.

Word / PowerPoint ▶ Markdown (+ HTML)

L'agent de remboursement de Léa

LE BESOIN

Un client réclame sur une commande (plat froid, article manquant, retard) : l'agent **identifie** la clause de la politique, **calcule** le geste, **l'applique** ou **escalade**.

LA CONTRAINTE

Ça traverse **plusieurs systèmes** (commandes, paiement, mail). **Argent réel**, clients authentifiés, tentatives de manipulation. La **politique** fait foi, pas le LLM.

CE QU'ON ATTEND


Autonomie bornée : l'agent rembourse sous le seuil (≤ 25 €, ≤ 2 remb./30 j), **escalade** au-dessus, **refuse** la fraude.

Échelle : niveau 3–4


LE RÉSULTAT CONCRET · ILLUSTRÉ SUR AWS

La même maquette d'archi — figée sur le cas de Léa, sur AWS

L'archi de l'agent de remboursement  **gouvernance renforcée** — identité · garde-fous · observabilité



L'architecture AWS de RestoAgent — l'implémentation derrière la démo



Les mêmes briques que la maquette, en services AWS réels : **AgentCore Runtime** (Strands + Claude Haiku 4.5) · **Gateway MCP + JWT** · **Cognito** (identité) · **AgentCore Memory** · **Bedrock Knowledge Base** (policy de remboursement) + **S3** · **CloudWatch** (observabilité). Outils exposés via un **MCP Server** (5 tools, identity-bound).

Et voici cette archi en action (niveau 3–4)

► **Démo — RestoAgent, l'agent de remboursement service client**

Où tournent les agents et les données ?

VÉRITÉ 1

« Région EU » ≠ souverain. Le **CLOUD Act** contraint un fournisseur US quelle que soit la localisation des données.

VÉRITÉ 2

Pas qu'une affaire de modèle. L'agent touche la donnée par ses **outils, sa mémoire et son observabilité** (piège : traces vers un SaaS US).

1

Hyperscaler région EU

résidence RGPD — mais juridiction US demeure

2

Cloud souverain

AWS Eur. Sovereign Cloud · S3NS — juridiction + résidence

3

Fournisseur EU (Mistral, OVH, Scaleway)

stack 100 % EU — modèles frontière un cran derrière

4

VPC privé + modèles open-weight

la donnée ne sort jamais — vous opérez l'inférence

5

On-prem / air-gapped

contrôle max — GPT/Claude/Gemini impossibles

Réponse pragmatique : l'**hybride par classe de données**. Non sensible → meilleure API frontière ; confidentiel → open-weight local ; un **AI gateway** route selon la sensibilité.

À EMPORTER

3 réflexes pour choisir sa techno d'agents

PLACER

le use case sur l'échelle (1 → 5). L'échelon décide tout le reste.

MUTUALISER

un seul socle agentique pour tous vos use cases.

runtime · mémoire · identité · gateway · garde-fous · observabilité — bâti une fois, réutilisé à tous les échelons

COMMENCER

bas, gouverner d'abord, monter délibérément.



Merci.

Jonathan Gross

jonathan.gross@kleegroup.com

Maxime Lamborelle

maxime.lamborelle@kleegroup.com

Présentation & outil à télécharger : github.com/woodyjon/klee-agentic

Klee Group · EBG, 25 juin 2026



Scannez pour la présentation &
l'outil